



Universidade Federal da Bahia
Instituto de Matemática e Estatística
Colegiado de Estatística

LUCAS RABELO DE ARAÚJO MORAIS

**Análise de resultados de marketing digital
de uma agência aérea usando web analytics
com previsão do retorno de investimento.**

Salvador

2022

LUCAS RABELO DE ARAÚJO MORAIS

**Análise de resultados de marketing digital de uma
agência aérea usando web analytics com previsão do
retorno de investimento.**

Trabalho de Conclusão de Curso
apresentado ao Curso de Gradua-
ção em Estatística, Colegiado de Es-
tatística, Instituto de Matemática e
Estatística, Universidade Federal da
Bahia, como requisito parcial à apro-
vação na disciplina de Trabalho de
Conclusão de Curso II.

Orientadora: Profa. Dra. Gecy-
nalda Soares da Silva Gomes

Salvador

2022

LISTA DE ILUSTRAÇÕES

Figura 1 – Jornada do consumidor (compra).	14
Figura 2 – Container ID para instalação do Tag Manager.	15
Figura 3 – Códigos do Container ID.	16
Figura 4 – Tela inicial do container para instalação do Tag Manager.	17
Figura 5 – Autorização da API do <i>Google Analytics</i> por meio do <code>googleAnalyticsR</code>	18
Figura 6 – Processo de API do Youtube.	18
Figura 7 – Conexão com banco de dados em PostgreSQL	19
Figura 8 – Acesso a API do <i>Twitter</i> no R.	20
Figura 9 – Estrutura de uma Rede Neural Artificial.	26
Figura 10 – Estrutura de uma Rede Neural Recorrente.	27
Figura 11 – Arquitetura de uma Rede Neural LSTM	29
Figura 12 – Palavras frequentes nos títulos das reclamações dos clientes da Voal.	34
Figura 13 – Palavras frequentes no conteúdo das reclamações dos clientes da Voal.	34
Figura 14 – Palavras correlacionadas no título das reclamações sobre a Voal.	35
Figura 15 – Palavras correlacionadas no conteúdo das reclamações sobre a Voal.	35
Figura 16 – Palavras frequentes nas pesquisas relacionadas ao nome da Voal.	36
Figura 17 – Popularidade do nome da Voal em pesquisas no <i>Google</i> .	37
Figura 18 – Palavras mais frequentes nos títulos de vídeos do youtube sobre a Voal.	38
Figura 19 – Palavras mais frequentes nas descrições dos seguidores da Voal no <i>Twitter</i> .	39
Figura 20 – Palavras correlacionadas nas descrições dos perfis dos seguidores no <i>Twitter</i> .	40
Figura 21 – Dashboard Shiny Exploratório da API.	41
Figura 22 – <i>Dashboard Shiny</i> Descritivo dos Resultados - ROI.	41
Figura 23 – Decomposição da Série Temporal do ROI do Marketing até Março de 2022	42
Figura 24 – Autocorrelação nos Lags da Série Temporal do ROI	43
Figura 25 – Previsões do Modelo ARIMA(2,0,1)(0,0,1)[7].	44
Figura 26 – Previsões do Modelo de Redes Neurais Recorrentes Simples	45
Figura 27 – Previsões do Modelo de Redes Neurais Recorrentes LSTM	45
Figura 28 – Intervalo Bootstrap 99% para as previsões da Rede Recorrente.	48
Figura 29 – Intervalo de predição 95% para o modelo RNN.	50

LISTA DE TABELAS

Tabela 1 – Distribuição das palavras X e Y no texto	22
Tabela 2 – Medidas de Erro no Conjunto de Teste.	46
Tabela 3 – Medidas de Erro dos Modelos Ajustados.	46

SUMÁRIO

1	INTRODUÇÃO	7
2	JUSTIFICATIVA	9
3	REVISÃO DE LITERATURA	11
4	METODOLOGIA	13
4.1	Definição de Termos	13
4.1.1	<i>Marketing Digital</i>	13
4.1.2	<i>Web Analytics</i>	14
4.2	Extração dos dados.	15
4.2.1	<i>Configuração do Google Tag Manager</i>	15
4.2.2	<i>API do Google Analytics no R</i>	17
4.2.3	<i>API do Youtube no R</i>	18
4.2.4	<i>Google Trends no R</i>	18
4.2.5	<i>Conexão com Banco de dados Postgresql no R</i>	19
4.2.6	<i>API do Twitter no R</i>	19
4.2.7	<i>Web Scraping</i>	20
4.3	Descrição dos Dados	20
4.4	Análise Estatística	21
4.4.1	<i>Pré-Processamento - Análise de Texto</i>	21
4.4.1.1	Correlação De Phi	22
4.4.2	<i>ROI - Return On Investment</i>	23
4.4.2.1	Média Móvel	23
4.4.2.2	Testes Para Séries Temporais	24
4.4.2.3	Modelo ARIMA	25
4.4.2.4	Redes Neurais	26
4.4.2.5	Estratégia de Previsão e Medidas de Erro	30
4.4.2.6	Intervalos de Previsão	31
4.4.2.7	Bootstrap Não Paramétrico	31
5	RESULTADOS	33
5.1	Branding - Reclamações dos Clientes	33
5.2	Dashboards	40
5.3	Série Temporal - ROI	42
5.4	Previsão do ROI	43

6	DISCUSSÃO	47
6.1	Estabilidade das previsões	48
6.2	Construção de intervalos de previsão	49
7	CONSIDERAÇÕES FINAIS	51
7.1	Limitações	51
7.2	Conclusão	51
	REFERÊNCIAS	53

Resumo

Os campos do *Marketing* Digital e da Estatística evoluíram consideravelmente da década de 80 para o século 21. No contexto do *Marketing* Digital, a Estatística pode ser utilizada para análise de dados textuais gerados de redes sociais, ou para criação de modelos com objetivo de inferência e/ou previsão de informações ao longo do tempo. Entretanto, como muitas vezes o comportamento dessas informações pode ser não-linear, o que pode tornar a análise de previsão muito complexa, deve-se buscar modelos que possam lidar bem com a característica de não-linearidade. Neste cenário de suma importância da estatística preditiva para o *marketing* e com o desenvolvimento computacional, métodos mais rebuscados como redes neurais também podem ser utilizados. De acordo com a literatura de aplicações de redes neurais no setor de negócios, na área de finanças muitos estudos passaram a ser usados com o intuito de prever o mercado de ações. O objetivo deste trabalho é analisar dados de *Marketing* Digital e de usuários de um serviço de uma companhia aérea, realizando previsões para o retorno financeiro por meio de modelos de redes neurais, como redes recorrentes e redes LSTM, e dos métodos de Box-Jenkins, Autotregressivos integrados e de médias móveis (ARIMA), e apresentar o uso de formas para analisar dados de estrutura textual. Por meio de ferramentas que possibilitam a medição de interações no *website*, foi possível ratificar como a Estatística está inserida no contexto do *Marketing* Digital, não apenas para a mensuração do retorno financeiro, mas também para análise de dados com estrutura textual de redes sociais e de fontes de terceiros disponíveis na *internet*. Para previsão, apesar do modelo de redes LSTM ter apresentado melhores medidas de previsão, similar ao que ocorre na literatura, o modelo de redes recorrentes simples além de ter sido superior ao modelo ARIMA, foi o mais eficiente no quesito computacional.

Palavras-Chave: Marketing Digital; Web Analytics; Dados de texto; Previsão de Séries Temporais com Redes Neurais; Previsão de Séries Temporais com ARIMA

1 INTRODUÇÃO

A evolução do campo do *Marketing* Digital, segundo Kamal (2016), pode ser datada por volta da década de 80, quando o primeiro computador pessoal da companhia IBM foi lançado no ano de 1981 e a companhia *Channel Net* conhecida anteriormente como *SoftAd Group* introduziu o conceito de *Marketing* Digital com ajuda de digitalização de diversas campanhas de publicidade.

Em 2002 o número de usuários em todo o mundo na internet era de 558 milhões, o que representa um crescimento percentual de 3387,5% em relação ao número de usuários no ano de 1995 que era de 16 milhões; em 2004 foram lançados o *Facebook* e o *Gmail*; em 2005 o termo de *Marketing* Digital ganhou notoriedade; e no ano de 2010 o crescimento do termo foi aproximadamente de 48%.

Diversas tendências surgiram com o avanço do *Marketing* Digital, como o uso de redes sociais para comunicação em tempo real da publicidade. Porventura a evolução dos meios de comunicação digitais contribuiu para o alto volume de dados comportamentais sobre o consumidor, que quando analisados podem auxiliar organizações a criar estratégias de *marketing* específicas para algum tipo de público.

JÄRVINEN e KARJALUOTO (2015), apontam que os consumidores estão, cada vez mais, interagindo com as companhias por meio de canais digitais. Devido a este fenômeno é interessante que as organizações comecem a utilizar de ferramentas de análise *web* (ou *web analytics*), para medir essas interações e a performance de seu *marketing*. O uso de ferramentas de *web analytics*, apesar de limitado a ambientes digitais é um importante passo para realizar *marketing* mensurável. A mensuração sobre os resultados gerados pelo *marketing digital* muitas vezes é realizada utilizando de medidas como o retorno sobre o investimento (ROI, do inglês *Return on Investment*), que é uma medida bastante conhecida e utilizada por empresas de diversos segmentos.

O uso da ciência Estatística está presente nos mais diversos campos da sociedade, seja científico, social ou no ramo de negócios em que pode ser utilizada juntamente com o *marketing*. Com o desenvolvimento do *marketing* digital e aumento da quantidade de usuários na internet, a quantidade de dados referente ao comportamento dos consumidores aumenta a cada segundo. No Brasil, segundo dados do IBGE (Instituto Brasileiro de Geografia e Estatística) publicados em uma matéria especial no ano de 2019¹ este cenário se reflete em um alto potencial de 82,7% de domicílios que têm acesso a serviços de internet.

¹ Disponível em: <<https://educa.ibge.gov.br/jovens/materias-especiais/20787-uso-de-internet-televisao-e-celular-no-brasil.html>> acesso em: 01 maio. 2022.

Com o processo de evolução do campo da Estatística da década de 80 para o século 21, em decorrência da melhoria do poder de processamento computacional, os métodos utilizados para a coleta dos dados também evoluíram, como o volume de informações aumenta exponencialmente cada vez mais, o uso de formatos comuns, como o .csv, ou .xlsx, utilizados na coleta, são deixados de lado, por aplicações criadas por APIs (Interface de Programação de Aplicação, do inglês Application Programming Interface), métodos de varredura de *website*, ou conexão com algum banco de dados.

A Estatística está inserida no contexto do *Marketing* Digital, não apenas para a mensuração do retorno financeiro, mas também para análise de dados com estrutura textual de redes sociais e de fontes de terceiros disponíveis na *internet*. Quando incluído o aspecto temporal (para o estudo de uma série temporal por exemplo - informação agregada coletada ao longo do tempo) nos dados pode ser interessante realizar a previsão de métricas essenciais para a avaliação do *marketing*.

Entretanto, como muitas vezes o comportamento dessas informações pode ser não-linear, o que pode tornar a análise de previsão muito complexa, deve-se buscar modelos que possam lidar bem com a característica de não-linearidade. Este trabalho lida com a previsão da série temporal de uma medida chamada de retorno sobre o investimento, no entanto devido a suas características de não-linearidade e por ser muito complexa, foram utilizados modelos de redes neurais, por serem capazes de se ajustar a essa característica, além disso também serão discutidos métodos para lidar com a incerteza das previsões.

O objetivo deste trabalho é analisar dados de *Marketing* Digital e de usuários de um serviço de uma companhia aérea, realizando previsões para o retorno financeiro por meio de modelos de redes neurais, como redes recorrentes e redes LSTM, e dos métodos de Box-Jenkins, Autorregressivos integrados e de médias móveis (ARIMA), e apresentar o uso de formas para analisar dados de estrutura textual.

2 JUSTIFICATIVA

Com o crescimento da quantidade de dados disponíveis na *internet* sobre o comportamento dos seus usuários, subsequente aos avanços tecnológicos do campo, diversos serviços passaram a ser prestados digitalmente por meio de *Ecommerce* (lojas *online*) que dependem de serviços de *Marketing* Digital para sua popularização, os quais podem ser prestados por agências de *Marketing* especializadas no ramo. A intersecção entre o *Marketing* Digital e a Estatística começa na coleta dos dados que são gerados pelos consumidores de serviços *online*, importantes para que a o ferramental estatístico seja utilizado para tomada de decisão. No entanto o campo da Estatística não permaneceu estático ao longo dos anos e com o crescimento da quantidade de dados, a forma de coleta das informações também evoluiu.

A coleta destes dados, que são gerados a cada segundo em que uma interação do usuário na *internet* é realizada, pode ser feita por meio de APIs, onde pode ser necessário que haja uma autorização específica da instituição que criou a aplicação, ou acesso a um banco de dados relacional construído em SQL (Linguagem de Consulta Estruturada, do inglês *Structured Query Language*), por meio de ferramentas que permitam o rastreo das ações realizadas no *Ecommerce* ou até utilizando de ferramentas de varredura de *website*.

Kolajo, Daramola e Adebiyi (2019) afirmam que os avanços tecnológicos que permitem este tipo de coleta de dados em tempo real (ou *streaming data*) trouxeram diversos desafios computacionais, o que demanda que suas análises sejam conduzidas também em tempo real. Com uma crescente demanda para este tipo de serviço as organizações precisam cada vez mais que os dados sejam rapidamente processados e analisados para que seja possível reagir a mudanças em tempo real, visto que este tipo de análise pode ajudar as organizações a encontrarem novas tendências que permitam uma melhoria em sua performance de resultados.

Este trabalho lida com os desafios de se utilizar dados reais de um cliente de uma empresa de *Marketing* Digital que são atualizados constantemente. Os dados são provenientes de diversas fontes utilizadas para a identificação de tendências em tempo real como: redes sociais, APIs, *sites* da internet e de um banco de dados relacional. Contudo para realizar a análise destes dados é necessário que sejam utilizados métodos não triviais, como a criação de *dashboards* e análise de texto.

Como o intuito da empresa, que busca esse tipo de análise, é a melhoria da performance dos resultados, é importante realizar previsões para eles, no entanto, muitas vezes as séries temporais podem ser difíceis de prever, principalmente se os dados são atualizados constantemente, o que leva a uma alteração na estrutura da série. Portanto, para

que um planejamento seja feito com base na previsão de valores de futuros resultados é importante que sejam utilizados modelos capazes de lidar com séries que não tem uma estrutura bem comportada e que este modelo esteja bem ajustado a série temporal de resultados, sendo parte importante deste trabalho realizar um ajuste para a previsão dos resultados do cliente desta empresa de *Marketing* Digital.

3 REVISÃO DE LITERATURA

A Ciência de Dados e o Big Data, que são campos englobados pela área da Estatística, tiveram um aumento de popularidade no século 21 e impactaram o *Marketing* em diversas áreas, como a estimação do valor da marca, a modelagem para a previsão da demanda e o estudo do comportamento do consumidor e suas preferências de consumo, ou seja, para obter vantagens competitivas, o *Marketing* tem que contemplar áreas da Estatística, sobretudo as mais contemporâneas como a Ciência de Dados, aprendizado de máquina, processamento de texto e processamento de áudio e vídeo (ROSÁRIO; MONIZ; CRUZ, 2021).

Dentre algumas medidas utilizadas para trazer vantagens competitivas a agências de *Marketing* Digital, está a mensuração do ROI diário, um indicador da situação financeira, que pode ser combinado com alguma estratégia de médias móveis, para melhorar a identificação da tendência e por conseguinte as tomadas de decisão, segundo Filho e Campos (2021), elas podem ajudar refletindo se o mercado está otimista ou pessimista.

No entanto, apenas o uso do ROI pode ficar muito vago, pois a medida, por exemplo, pode perder importância quando o *Marketing* é feito em redes sociais. Villavicencio (2014), discute o uso de formas alternativas para avaliar o impacto do *branding* (reconhecimento de marca) nestas plataformas, por meio de técnicas aplicadas a dados de estrutura textual, como análise de sentimento de um comentário em uma rede social, ou o percentual de citações de uma determinada palavra em um texto.

Ainda no âmbito de mineração de texto, Carvalho e Francisco (2017) utilizaram dados textuais coletados por meio de transcrições de conversas telefônicas, obtidas de um *call center* de uma empresa do mercado financeiro, contando com técnicas de mineração de texto como nuvens de palavras e redes de associações entre palavras. Com isso, conseguiram identificar as principais demandas dos clientes, pedidos que foram cancelados, motivo do cancelamento e a razão da ineficiência a ofertas de novos produtos, recomendando que fossem feitos futuros trabalhos inspirados em sua pesquisa, no contexto de outros negócios, para que se tenha maior evidência da identificação de *insights* de negócios, por meio de técnicas de análise de dados textuais.

No entanto, técnicas estatísticas mais rebuscadas também podem ser utilizadas no setor de *Marketing* a exemplo dos autores Armstrong, Brodie e McIntyre (1987) que realizaram uma revisão da literatura de diversos métodos de previsão utilizados na área, os resultados da pesquisa realizada demonstraram que segundo um questionário aplicado a 850 companhias americanas de *Marketing*, das 134 que responderam 98,6% realizam previsões quando precisam preparar planos formais de *Marketing*, num questionário anterior

93% responderam que previsões de vendas eram um dos aspectos mais críticos e/ou mais importantes para o sucesso de uma companhia.

Neste cenário de suma importância da estatística preditiva para o *marketing* e com o desenvolvimento computacional, métodos mais rebuscados como redes neurais também podem ser utilizados, Wong, Bodnovich e Selvi (1997) traçaram uma análise da literatura de aplicações de redes neurais no setor de negócios, na área de finanças por exemplo relativamente mais estudos passaram a ser publicados com o uso de redes neurais para a previsão de ações.

Na área de *Marketing* os autores Wong, Bodnovich e Selvi (1997) encontraram 10 artigos, no período de 1988 até 1995, sendo que 2 desses artigos se referiam ao uso de redes neurais para previsão de passageiros de uma linha aérea internacional e de futuros pedidos, já referente ao estado da arte das aplicações de redes neurais, Abiodun et al. (2018) de 12 estudos realizados entre 2009 e 2018, 5 tiveram como objetivo a aplicação de redes neurais para a previsão no setor de *Marketing*.

4 METODOLOGIA

Para este trabalho foram utilizados dados de um serviço de *Marketing Digital* e *web analytics* prestado por uma agência de performance digital, de nome fictício “Otis”, para uma agência aérea brasileira, de nome fictício “VoaL”. Os nomes fictícios foram utilizados para preservar a identidade das duas empresas envolvidas.

Para a coleta de dados referentes ao *website* da VoaL foi utilizada a API do *Google Analytics*, onde os dados foram extraídos usando o pacote `googleAnalyticsR` do software R e a autenticação da API via pacote `googleAuthR`. Nesse processo foram capturadas métricas relacionadas a parte do *Web Analytics*, como a quantidade de usuários no *site*, pesquisas por trajetos de viagem e localização geográfica da pesquisa.

Para ter acesso a API do *Google Analytics* é necessário que uma conta esteja registrada na ferramenta e os dados do *website* estejam sendo enviados para ela. A empresa *Google*, disponibilizou o serviço do *Google Tag Manager* em que é possível configurar *tags* de código customizadas para enviar informações sobre o comportamento dos usuários em *websites*, o serviço simplifica e centraliza o envio de dados do *website* para diversas ferramentas de *Web Analytics* e *Marketing Digital* como o *Google Ads* ou *Facebook Ads*.

4.1 Definição de Termos

Alguns termos, específicos ao trabalho e não necessariamente estão relacionados a área da Estatística, mas aos campos do *Marketing* e *Web Analytics* serão definidos a seguir.

4.1.1 *Marketing Digital*

Diversos materiais em *sites* na internet, artigos similares aos de JÄRVINEN e KARJALUOTO (2015) e Kamal (2016) e livros apresentam introduções ao *Marketing Digital* e podem ajudar a definir alguns termos. Um dos trabalhos notáveis na introdução ao *Marketing Digital* é o livro da autora Diamond (2019), da coleção *For Dummies*, em que é possível encontrar a explicação de algumas das nomenclaturas:

- **Marketing Digital** é um termo bastante amplo e pode significar desde uma simples postagem em uma rede social, como a construção de artigos em blogs ou *sites* visando estratégias de otimização de ferramentas de busca (SEO - *Search Engine Optimization*);
- **SEO** é uma estratégia aplicada a ferramentas de busca, como o *Google*, que ajudam os potenciais clientes a encontrarem um serviço por meio de palavras-chave, as quais, por exemplo, podem ser inseridas em um artigo ou no título de algum produto;

- **Branding** é utilizado para o reconhecimento e o crescimento de marca, e é importante pois ajuda a diferenciar a marca dos competidores, cria clientes leais, os ajudando a recomendar a marca de maneira amigável a seus amigos e familiares e além disso pode ajudar na satisfação do empregado da empresa, encorajando sua retenção;

- **Campanhas** são criadas quando seus objetivos de negócio incluem mover o cliente sobre a jornada do consumidor, essas ações que podem ser exemplificadas na **Figura 1** retirada do *website Marketing Por Dados*¹, quando coordenadas corretamente são denominadas campanhas. As campanhas têm um conjunto específico de características em comum, pois são baseadas em objetivos, são multiparcionadas, podendo incluir formulários ou emails e podem ser coordenadas tanto em um curto (dias) como um longo espaço de tempo (anos);

Figura 1 – Jornada do consumidor (compra).



Fonte: Artigo do website Marketing Por Dados

4.1.2 Web Analytics

Para as ferramentas de *web analytics* a nomenclatura utilizada se detêm as plataformas da Google, o *Google Tag Manager* (GTM) e o *Google Analytics*, e pode ser encontrada no trabalho de Weber (2015):

- **Web Analytics** que indica por natureza a mensuração de páginas *web*, podendo se referir a ferramenta responsável por coletar dados de tráfego do consumidor na *web*, sendo o *Google Analytics* e o GTM ferramentas que utilizam de códigos de Javascript para realizar a mensuração da ação do usuário no *website*;

- **Tags** são códigos em Javascript, que ao serem instalados no *website* podem realizar a mensuração de algum evento realizado no *site*;

¹ Disponível em: <<https://marketingpordados.com/marketing/jornada-do-consumidor/>> acesso em: 16 abril. 2022.

- **Tipos de Tráfego** indicam o canal de como o usuário chegou no *website*, podem ser classificados como orgânico (cujo usuário digita o *website* no buscador), direto (o qual o nome do *site* é digitado diretamente no *browser*), redes sociais (onde o usuário veio por meio de uma rede social) e referência (quando o usuário chega no *site* por meio de um *link*). Os tipos de tráfego também podem ser customizados possibilitando a adição de novas fontes;

4.2 Extração dos dados.

Nas próximas subseções serão descritas as etapas necessárias para obtenção dos dados a serem utilizados neste trabalho e a configuração das ferramentas necessárias para coletá-los, mais informações sobre os termos técnicos e funcionamento das ferramentas podem ser encontradas em [Google Developers \(2022\)](#) e [Brys \(2016?\)](#).

4.2.1 Configuração do Google Tag Manager

Para a instalação do *tag manager*, que possibilitará a coleta de dados do *website*, para alguma das ferramentas de *web analytics*, como o *Google Analytics* ou *Google Ads*, deve ser feita a criação da conta para o cliente. Posteriormente será habilitado o acesso aos *containers* (containers são conjuntos de códigos que serão implementados em sites), sendo que cada conta pode ter mais de um *container* onde será configurado o código de acompanhamento do *site*.

Após feita a conta, a parte mais importante é repassar o código do *container* para que alguém que tenha acesso ao código interno do website (de preferência algum desenvolvedor) possa colocá-lo na estrutura de código `html`, este código se encontrará ao clicar no *container ID*, como mostra a **Figura 2**. Apesar de contatar o desenvolvedor do *site* ser uma das formas mais comuns de instalar o *container ID*, dependendo da ferramenta utilizada para construir o *website* outras opções de instalação de código são possíveis, onde não necessariamente tenha que ser envolvido alguém que desenvolveu o *website*.

Figura 2 – Container ID para instalação do Tag Manager.




Fonte: Install Google Tag Manager for web pages, [Google Developers \(2022\)](#)

Após o clique no *container ID*, serão apresentados na tela dois *chunks* de código como mostra a **Figura 3**, onde na estrutura `html` da página a primeira parte do código

deve ser colocada imediatamente após o início da *tag* <head>, já a segunda parte deve ser colocada logo após o início da *tag* <body>. Com a configuração realizada, o *tag manager* estará pronto para capturar os dados do *website* e enviar para as plataformas de *Marketing Digital* e *Web Analytics*.


Figura 3 – Códigos do Container ID.



Fonte: Install Google Tag Manager for web pages, [Google Developers](#) (2022)

O *layout* inicial do *tag manager* ilustrado na **Figura 4**, apresenta algumas abas como a “*Overview*” onde há um resumo das atividades da conta, em “*Tags*” é configurada a ferramenta de *Marketing Digital* e *Web Analytics* de escolha, os eventos que serão capturados (como o clique em algum botão, visualização de páginas, compra de algum item, assinatura de formulários, etc.) e como eles devem ser enviados para essas plataformas, em “*triggers*” é configurada o momento em que as *tags* configuradas serão acionadas, ou seja, quando elas serão enviadas. Já em “*variables*” podem ser extraídas informações importantes para o envio de valores (como o nome de alguma página do *site*, ou algum formulário) para as *tags* e *triggers*. Por fim, além de poderem ser organizadas em pastas na aba “*Folders*”, *tags* e variáveis customizadas são definidas em “*templates*”.

Figura 4 – Tela inicial do container para instalação do Tag Manager.



Fonte: Elaboração Própria

4.2.2 API do Google Analytics no R

O *Google Analytics* é uma ferramenta de acompanhamento do *site*, sendo utilizada tanto para o *web analytics* quanto para o *Marketing Digital*. Os dados da conta da Voal foram coletados pela API do *Google Analytics* em conexão com o *software R* por meio dos pacotes `googleAnalyticsR` e `googleAuthR`. Idealmente a configuração da API deve ser feita por meio de uma plataforma da *Google* chamada *Console Cloud Platform* que é responsável por liberar acessos a diversos serviços da empresa dentre os quais as APIs. Após a criação ou acesso a conta desejada no *Google Analytics*, é necessário criar uma tela de consentimento (processo que pode ser realizado dentro do próprio *Console Cloud Platform*) para ter acesso a quota individual da API, após este processo são disponibilizadas as credenciais para utilização do aplicativo da API, as quais são o *Client ID* e o *Client Secret*.

No entanto, a credenciação da API não foi feita pelo *Console Cloud Platform*, já que foi utilizada uma funcionalidade dos pacotes `googleAnalyticsR` e `googleAuthR` citada por Brys (2016?) e realizado conforme a **Figura 5**, onde o processo de credenciação da API é facilitado, pois as credenciais já estão incluídas no pacote, contudo, a quota da API é compartilhada entre todos os usuários do pacote, apesar da limitação, não houveram transtornos, havendo a opção de utilizar as próprias credenciais já criadas no *console cloud* se necessário.


Figura 5 – Autorização da API do *Google Analytics* por meio do `googleAnalyticsR`

Fonte: Elaboração Própria

4.2.3 API do Youtube no R

Para campanhas a nível de *branding*, o *Youtube* contém diversas informações importantes, o acesso a API por meio do R foi feito pelo pacote `tuber`, o processo está detalhado na **Figura 6**, e é similar ao adotado para ter acesso a API do *Google Analytics*, onde foi aproveitada da tela de consentimento criada, mas não utilizada na implementação do `googleanalyticsR` para ter acesso a quota da API que é individual, posteriormente foi habilitada a API do *Youtube* e realizado todo o processo de autorização do pacote `tuber` aos dados da conta.

Figura 6 – Processo de API do Youtube.



Fonte: Elaboração Própria

4.2.4 Google Trends no R

O *Google Trends*, utilizado comumente em estratégias de SEO, é uma ferramenta *web* gratuita disponibilizada pela *Google*, onde está disponibilizado a popularidade de termos que são pesquisados no buscador da *Google*, também foi utilizado para identificar os termos relacionados ao nome da Voal e capturar possíveis *insights*. No entanto o


processo para ter acesso aos dados é bastante simples, bastando utilizar a função `gtrends` do pacote `gtrendsR`.

4.2.5 Conexão com Banco de dados PostgreSQL no R

Os dados relevantes ao investimento realizado nas campanhas de *Marketing* do *Google Ads* e o cruzamentos de dados, necessário para saber quais compras realmente foram realizadas no *site*, entre os dados presentes no *Backend* (referem-se aos dados internos da empresa, que não são coletados por meio das ferramentas de *Web Analytics*) da VoaL e os do *Google Analytics* foram coletados via conexão com um banco de dados construído em PostgreSQL pela Otis.

A conexão com o banco de dados foi feita utilizando seguindo o processo ilustrado na **Figura 7**, para tal foi utilizado o *software* R e seus pacotes: DBI responsável por fazer a comunicação entre o R e o sistema de gerenciamento de base de dados relacionais e o pacote `Rpostgresql`, que disponibiliza uma interface DBI para permitir que o R acesse os dados do banco, as credenciais de acesso ao banco de dados foram fornecidas pela empresa Otis.

Figura 7 – Conexão com banco de dados em PostgreSQL



Fonte: Elaboração Própria


4.2.6 API do Twitter no R

O processo para acessar a API do *Twitter* é um pouco mais burocrático, pois apesar de gratuita, requer uma autorização da companhia, portanto como explicitado na **Figura 8** é necessário que seja realizado um contato com o time internacional do *Twitter* por meio do portal do *Twitter Developer Platform*, explicitando os motivos para a utilização dos dados da rede social.

Após a liberação da API pelo *Twitter*, deve ser criado um projeto para utilizar a quota da aplicação, e salvar as credenciais necessárias (as quatro credenciais são o `consumer_key`, o `consumer_secret`, o `bearer_token`, o `access_token` e o `access_secret`) para realizar a autenticação com o *software* R. O pacote `twitterR` dispõe da função

`setup_twitter_oauth` para que a autenticação seja realizada e foi utilizado em conjunto com o `rtweet` para auxiliar no processo de extração de dados da API.

Figura 8 – Acesso a API do *Twitter* no R.



Fonte: Elaboração Própria

4.2.7 Web Scraping

Para o *Web Scraping*, também conhecido como processo de varredura do *site* (técnica utilizada para extrair dados de *websites* por meio do HTML), foram utilizadas as linguagens R e Python. O R foi utilizado para coletar os códigos IATA dos aeroportos do Brasil (códigos de identificação geográfica do aeroporto), os quais foram posteriormente integrados na base dados da API.

No entanto, ao seguir para a coleta de dados reclamações dos clientes da Voal postadas em um *site* utilizado para esse fim, a varredura realizada com a biblioteca **Rvest** retornou o erro 403, impossibilitando uma conexão à página **html** do *site* de reclamações, por conseguinte na busca por uma alternativa foi utilizado o pacote **Selenium** da linguagem Python, o qual, além de ter facilitado o processo de varredura da estrutura **html** da página, solucionou o problema do erro.

4.3 Descrição dos Dados

Os dados tem como fonte principal uma empresa classificada como agência aérea brasileira, onde são capturados dados do seu *website* por meio do *Google Analytics*, com informações sobre o comportamento dos clientes no *site* e sobre as buscas por trechos de viagem, as quais são relevantes para realização de campanhas de *Marketing* Digital. Dados sobre os investimentos realizados por dia para campanhas de *Marketing* pela empresa de performance digital, para a conta da Voal no *Google Ads* também foram disponibilizados, para a previsão os dados da série temporal do ROI, foram atualizados até o dia 15 de Agosto de 2022.

Além disso, o acesso a API dos dados, com informações do *Backend* que vão do ano de 2016 e são atualizadas quase que diariamente foi disponibilizado pela agência. Com os dados do *Google Analytics* e os dados internos da VoaL, foi feito um cruzamento de dados, para verificar a falta de registro do *Google Analytics*, que pode ocorrer por diversos motivos, como o uso de bloqueadores de anúncio ou navegadores especiais e o ROI das campanhas de *Google Ads* realizadas pela empresa de performance digital. As técnicas de *web scraping* foram utilizadas para criar uma base de dados com os códigos IATA dos aeroportos do Brasil.

Para avaliar o comportamento dos clientes em relação a marca em redes sociais, os dados provenientes da API do *Twitter* foram coletados, ainda neste campo *Web Scraping* foi utilizado para analisar em *sites* de reclamações, possíveis motivos que levaram clientes a estar insatisfeitos com a VoaL. Ainda na seara das redes sociais, os dados da API do *Youtube* foram utilizados para avaliar os tipos de vídeos que foram lançados falando sobre a VoaL. Para ajudar na análise do crescimento orgânico (crescimento que não é impulsionado por campanhas de *marketing*) o *Google Trends* foi utilizado para avaliar o termos “VoaL” no buscador *Google*.

4.4 Análise Estatística

Esta seção traz formulações matemáticas de algumas das estatísticas utilizadas para auxiliar nas análises, bem como o pré-processamento realizado para as técnicas de análise de texto, testes para os componentes das séries temporais, especificações dos modelos e medidas de erro para previsões.

4.4.1 Pré-Processamento - Análise de Texto

Para a seleção de palavras e aplicação dos métodos de análise de texto, como a construção de nuvens de palavras, onde diversas palavras são destacadas e aquelas com maior frequência aparecem em maior tamanho a exemplo da Figura 15, foi necessário realizar um pré-processamento. Em suma o pacote utilizado para o pré-processamento foi o **tm**, em que a função **Corpus** foi usada para transformar os dados textuais em uma estrutura **Corpus**.

Ainda de acordo com [Silge e Robinson \(2017\)](#) uma estrutura **Corpus** é similar a uma lista, onde cada item contém texto e metadados (mais detalhes podem ser consultados na documentação do pacote **tm**). Após colocar os dados textuais na estrutura **Corpus**, foi utilizada a função **tm_map** para filtrar os textos, onde todas as palavras foram transformadas em minúsculas, tiveram a pontuação (como hífen e vírgula) e acentuação removidas e seus espaços em branco removidos, por fim gerando uma matriz de termos (também chamada *document-term matrix*).

```

corpus <- tm_map(corpus, content_transformer(tolower))
corpus <- tm_map(corpus, removePunctuation)
corpus <- tm_map(corpus, removeNumbers)
corpus <- tm_map(corpus, removeWords, stopwords("portuguese"))
corpus <- tm_map(corpus, stripWhitespace)
corpus_matrix <- as.matrix(TermDocumentMatrix(corpus))
words <- sort(rowSums(corpus_matrix),decreasing=TRUE)

```

Em uma matriz de termos e documentos cada linha representa um documento, cada coluna representa um termo (palavra) e os valores são o número de vezes que o termo aparece no documento, a quantidade de vezes em que cada palavra aparece nos documentos foi somada utilizando a função `rowSums`, além disso, o verdadeiro nome da companhia VoaL foi omitido nesta etapa, para garantir a confidencialidade da sua razão social e a palavra “não” foi omitida na construção da nuvem de palavras devido a sua elevada frequência, o que acabava ofuscando outras palavras da nuvem.

4.4.1.1 Correlação De Phi

Baseado no trabalho de [Silge e Robinson \(2017\)](#), a função utilizada neste trabalho para calcular associações entre palavras na análise textual foi a `pairwise_cor`, disponível no pacote `widyr`, aplicada após a atribuição de um ID a cada texto e a separação de suas palavras por meio da função `unnest_tokens` do pacote `tidytext`.

A função `pairwise_cor` na verdade corresponde a correlação de phi, que é calculada a partir de *bi-grams*, ou seja, pares de palavras X e Y que aparecem juntas, configuradas de modo que teremos a relação da **Tabela 1**, onde o foco é dizer o quão provável é que os pares X e Y apareçam juntos ou não apareçam em documentos de texto.

Tabela 1 – Distribuição das palavras X e Y no texto

	Tem a palavra Y	Não tem a palavra Y	Total
Tem a palavra X	n_{11}	n_{10}	$n_{1.}$
Não tem a palavra X	n_{01}	n_{00}	$n_{0.}$
Total	$n_{.1}$	$n_{.0}$	n

Fonte: Traduzido de [Silge e Robinson \(2017\)](#)

A correlação pode ser calculada como na **equação 4.1**, onde seus valores variam de -1 até 1 e segundo o autor [Zhang \(2018\)](#), quando o valor é maior ou igual a 0 e menor que $0,3$ existe pouca ou nenhuma correlação, maior ou igual a $0,3$ e menor que $0,7$ existe uma fraca correlação e maior ou igual a $0,7$ até $1,0$ a correlação pode ser considerada

forte, tendo uma interpretação similar a do coeficiente de correlação de Pearson, no geral a correlação de Phi é apresentada em conjunto com o gráfico de correlação (ver Figuras 14, 15 e 20) onde estão ligadas as palavras que apresentam algum tipo de associação, atrelada ao coeficiente de correlação entre si.

$$\phi = \frac{n_{11}n_{00} - n_{10}n_{01}}{\sqrt{n_{1.}n_{0.}n_{.0}n_{.1}}} \quad (4.1)$$

Mais detalhes sobre a literatura do pré-processamento e de análise de dados textuais, podem ser encontrados em Zhang (2018) e Silge e Robinson (2017).

4.4.2 ROI - Return On Investment

Retorno ao investimento (ROI) é uma medida geralmente utilizada para avaliar a eficiência de um investimento ou realizar comparações dentre diversos investimentos diferentes, apesar de poder ser calculado de diversas maneiras, tanto sua definição como seu cálculo foi inspirado no trabalho de Botchkarev e Andru (2011), onde para cada dia t , o ROI_t pode ser calculado conforme a **Equação 4.2**:

$$ROI_t = \frac{\text{Receita}_t - \text{Custo}_t}{\text{Custo}_t} \quad (4.2)$$

Apesar de existirem diversas maneiras de se calcular o ROI, no geral um ROI de 100% implica que a quantidade de dinheiro ganho foi igual a quantidade de dinheiro investido, sem retorno adicional, ou seja, o capital recebido foi o suficiente para que o investimento fosse pago. Na formulação proposta, um ROI de 100% significa que houve não apenas o retorno do capital investido, mas também que o lucro foi igual ao investimento.

4.4.2.1 Média Móvel

Uma série temporal é uma sequência de dados agregados que foram coletados em diversos pontos no tempo, nesta seara, médias móveis podem ser utilizadas como método para a decomposição da tendência da série, de acordo com Hyndman (2009). A média móvel unilateral pode ser calculada da seguinte maneira:

$$z_t = \frac{1}{k+1} \sum_{j=0}^k y_{t-j} \quad (4.3)$$

A série de médias móveis resultante terá média móvel de $m = k + 1$ unilateral (ou seja se $k = 3$ a média móvel é de ordem 4), no entanto sua suavização não foi utilizada para a identificação da tendência a longo prazo, mas para que pudesse dar suporte ao planejamento de recursos da empresa, por resumir o comportamento médio no período

escolhido, servindo como indicativo do impacto que as estratégias de *Marketing* tiveram no período.

4.4.2.2 Testes Para Séries Temporais

Para a previsão de séries temporais, muitos modelos possuem o pressuposto de estacionariedade, portanto deve-se verificar se a série possui componentes de tendência e sazonalidade bem definidos, além de ser realizada a análise gráfica da decomposição dos componentes da série, é desejável que sejam realizados testes para verificar os pressupostos.

Para a avaliação dos componente de tendência pode ser utilizado o teste de Mann-Kendall em que a hipótese nula consiste na ausência de tendência na série, e sua estatística pode ser definida como a soma dos postos das diferenças dos valores sequenciais x_i e x_j com $i < j$, ou seja, com base em [Burn e Elnur \(2002\)](#) a estatística é definida como

$$S = \sum_{i=1}^{n-1} \sum_{j=i+1}^n \text{sgn}(x_j - x_i) \text{ e } \text{sgn}(\theta) \begin{cases} +1 & , \theta > 0 \\ 0 & , \theta = 0 \\ -1 & , \theta < 0 \end{cases}$$

O teste de Kwiatkowski-Phillips-Schmidt-Shin (ou teste KPSS), é um teste não-paramétrico com a hipótese nula de estacionariedade. De acordo com [Nielsen \(2005\)](#), a estatística de teste pode ser calculada de maneira que, assumindo que não há tendência, $Y_t = \xi_t + e_t$, em que e_t possui estacionariedade e $\xi_t = \xi_{t-1} + v_t$ é um passeio aleatório com $v_t \sim IID(0, \sigma_v^2)$ de modo que se a variância for 0 então $\forall t \xi_t = \xi_0$ e Y_t é estacionário, uma regressão simples de forma $Y_t = \hat{\mu} + \hat{e}_t$ com $\hat{e}_t$ estacionário sob a hipótese nula, é usada para estimar o componente estocástico, com a estatística de teste em **Equação 4.4** tendo forma:

$$KPSS = \frac{1}{T^2} \frac{\sum_{t=1}^T S_t^2}{\hat{\sigma}_\infty^2} \quad (4.4)$$

em que $S_t^2 = \sum_{s=1}^t \hat{e}_s$ é uma soma parcial dos resíduos e $\hat{\sigma}_\infty^2$ é um estimador da variância de $\hat{e}_s$.

Para a verificação do componente sazonal pode ser realizado o teste de Kruskal-Wallis, definido em [Morettin e Tolo \(2004\)](#), em que a cada coluna de uma tabela pode ser suposta uma amostra da população, ou seja a composição é feita de k amostras de tamanho n_j , sendo Y_{ij} a i -ésima observação da amostra j , ou seja $j = 1, 2, \dots, k$ e $i = 1, 2, \dots, n_j$ com $N = \sum_{j=1}^k n_j$. As observações Y_{ij} devem ser substituídas pelos seus postos R_{ij} , os quais são obtidos ao se ordenar todas as N observações, com $R_{.j} = \sum_{i=1}^{n_j} R_{ij}$, a estatística de teste portanto, pode ser calculada com

$$T_1 = \frac{12}{N(N+1)} \sum_{j=1}^k \frac{R_{.j}^2}{n_j} - 3(N+1) \quad (4.5)$$

em que a hipótese nula de não existência de sazonalidade é rejeitada se $T_1 \geq T_{1c}$ (sendo T_{1c} o valor crítico da estatística T_1) com base em um nível α de significância.

Além de analisar o comportamento da série, outro objetivo nesse tipo de estudo é realizar previsões de observações futuras. Para isso, inicialmente, pode-se calcular a entropia espectral de Shannon que é uma medida de quão “fácil” a série é de prever, de acordo com Hyndman e Athanasopoulos (2021), uma série com alta sazonalidade e tendência (bem comportada) terá uma entropia perto de 0, enquanto uma série com muitos ruídos, logo difícil de prever, terá uma entropia perto de 1. De acordo com Goerg (2012) a entropia espectral de Shannon é definida conforme a equação 4.6 e a densidade é normalizada² de maneira que $\int_{-\pi}^{\pi} f_x(\lambda) d\lambda = 1$, a entropia foi calculada utilizando o pacote `feasts` do R.

$$H_{spec} = - \int_{-\pi}^{\pi} f_x(\lambda) \log_a f_x(\lambda) d\lambda \quad (4.6)$$

De acordo com Morettin e Toloi (2004), diversos testes para testar a não-linearidade de uma série temporal foram propostos, como o teste de Keenan, onde na hipótese nula queremos testar se a série temporal segue um processo autorregressivo. Sumarizado pelos autores Lee, White e Granger (1993), considerando uma série y_t e uma variável independente $X_t = (y_{t-1}, y_{t-2}, \dots, y_{t-p})$ usada para explicar y_t com p arbitrário, o primeiro passo deste teste é realizar uma regressão linear de y_t em $\tilde{X}_t$ produzindo previsões $f_t = \tilde{X}_t' \hat{\beta}$. Essencialmente o teste se baseia na correlação entre f_t^2 e os resíduos estimados $\hat{e}_t = y_t - f_t$, para verificar se o quadrado das previsões têm algum tipo de habilidade para previsão, testando, portanto desvios sobre a linearidade da média. O teste está disponível na função `nonlinearityTest` do pacote `nonlinearTseries` do *software* estatístico R.

4.4.2.3 Modelo ARIMA

O modelo ARIMA (modelo autorregressivo integrado de médias móveis, do inglês *autoregressive integrated moving average model*), utilizado neste trabalho, é um dos métodos mais utilizados de previsão de séries temporais, a função `auto.arima` do *software* estatístico R já possui um teste de estacionariedade para a estimação do parâmetro de diferenciação e pode ser usada diretamente para este fim. Autores como Morettin e Toloi (2004) e Hyndman e Athanasopoulos (2021), utilizam duas abordagens diferentes para explicar o modelo, sendo respectivamente, uma mais teórica e outra computacional.

O modelo ARIMA é uma combinação de três modelos, um autorregressivo $AR(p)$ em que p corresponde a ordem da parte autorregressiva (o termo autorregressão indica que há uma regressão de uma variável com ele mesma), o integrado $I(d)$ de ordem d , sendo

² Informação também disponível no CRAN do pacote `feasts` do R em: <<https://cran.r-project.org/web/packages/feasts/feasts.pdf>> acesso em: 02 junho. 2022.

d o grau da diferenciação. A diferenciação é utilizada para transformar uma série não estacionária em uma série estacionária e pode ajudar a estabilizar a média de uma série temporal, eliminando ou reduzindo a tendência e a sazonalidade. O modelo de médias móveis corresponde a $MA(q)$, em que q é a ordem da parte de médias móveis. A equação do modelo cheio é ilustrada a seguir:


$$y'_t = c + \phi_1 y'_{t-1} + \cdots + \phi_p y'_{t-p} + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q} + \varepsilon_t \quad (4.7)$$

em que y'_t corresponde a série diferenciada.

4.4.2.4 Redes Neurais

Os modelos de redes neurais são métodos de previsão que são inspirados na arquitetura do cérebro, eles permitem a modelagem de relações não-lineares complexas entre a variável resposta e as preditoras. O modelo, para a previsão de séries temporais, conta com três camadas, a camada de entrada, a camada escondida e a camada de saída, cada camada - exceto a de saída - pode conter mais de um neurônio, na **Figura 9** os autores [Hyndman e Athanasopoulos \(2021\)](#) trazem uma exemplificação da estrutura das redes neurais.

Figura 9 – Estrutura de uma Rede Neural Artificial.



Fonte: Forecasting: Principles and Practice, [Hyndman e Athanasopoulos \(2021\)](#)

Para uma rede neural com três camadas, [Brezak et al. \(2012\)](#) define a entrada do j -ésimo neurônio da camada escondida da n -ésima amostra de aprendizado, exceto para o bias, que é um parâmetro com valor sempre igual a 1, como $net_j(n) = \sum_{i=1}^I v_{j,i} x_i(n)$, $j = 1, \dots, J - 1$, em que I é o número de neurônios da camada de entrada, v são os seus pesos (os pesos são selecionados na estrutura da rede neural usando um algoritmo de aprendizado que minimiza uma função de custo) e x são as suas entradas. Na camada

escondida as entradas são modificadas para gerar uma saída com base em uma função de ativação não-linear, a qual pode ser uma *sigmoid* bipolar, dada por

$$y_j(n) = \frac{2}{1 + e^{-c_j net_j(n)}} - 1, j = 1, \dots, J - 1 \quad (4.8)$$

c_j é um parâmetro de ganho (geralmente é de 0,1), utilizado para fazer a rede neural robusta contra *outliers*, o valor de saída do bias é $y_j = 1$.


O último m -ésimo valor de saída da rede é definido, após somadas todas as saídas dos neurônios da camada escondida (incluindo o bias) e os pesos w (gerados na saída), como:

$$O_m(n) = \sum_{j=1}^J y_j(n) w_{mj}, m = 1, \dots, M \quad (4.9)$$

Os parâmetros v , w e c são estimados no processo de aprendizado.

Já as redes neurais recorrentes são uma extensão das redes neurais artificiais. Diferentemente das redes apresentadas, esse tipo de rede neural é caracterizada por um modelo dinâmico de neurônio e foram desenvolvidas pois as redes neurais artificiais possuem menos memória e não conseguem lidar muito bem com dependências temporais, a essência das redes neurais recorrentes é considerar a informação do passado para gerar uma saída.

Figura 10 – Estrutura de uma Rede Neural Recorrente.



Fonte: Deep learning methods for forecasting COVID-19 time-Series data, [Zeroual et al. \(2019\)](#)

O artigo online da [Data Science Academy \(2022?\)](#) e o artigo de [Zeroual et al. \(2019\)](#) utilizam-se de fórmulas similares para explicar a arquitetura da rede neural recorrente, a exemplo da **Figura 10**, basicamente uma parte da rede neural A recebe a informação de

uma entrada x_t e como saída passa adiante uma informação de estado oculto h_t calculada como:

$$h_t = g(W_{x_t} + Uh_{t-1}) \quad (4.10)$$

Sendo W uma matriz de peso, h_{t-1} o estado oculto do passo de tempo anterior e U uma matriz de estado oculto, também conhecida como matriz de transição semelhante a uma cadeia de Markov e g uma função *sigmoid*.

No entanto, devido a problemas de desaparecimento do gradiente que limitam a eficiência das redes neurais recorrentes simples, foram desenvolvidas as redes neurais recorrentes LSTM (*Long Short Term Memory* - Memória de Curto Longo Prazo) que de acordo com [Zeroual et al. \(2019\)](#) são mais eficientes para lidar com dependências temporais, diversos materiais sobre este tipo de rede neural recorrente estão disponíveis na internet, dentre eles o produzido por [Richard Wanjohi \(2018\)](#), detalhando a implementação das redes LSTM no *software* R.

As redes LSTM são definidas por [Richard Wanjohi \(2018\)](#) como blocos de memória, chamados de células, que são conectados por camadas. A informação nas células é contida no estado celular e nos estados escondidos, sendo regulada por meio de mecanismos conhecidos como portões, por meio de funções de ativação *sigmoid* e tangente hiperbólica, os 3 portões principais que controlam o fluxo de informação são chamados de portão de esquecimento, portão de entrada e portão de saída.

Os portões são formados por funções *sigmoid*, com estrutura explicitada na **Figura 11**, em que I_t é o portão de entrada, F_t o portão de esquecimento e O_t o portão de saída, $\check{C}_t$ e C_t são respectivamente o estado intermediário da célula e o estado celular (a próxima entrada da memória), além disso cada camada *sigmoid* tem como saída um número entre 0 e 1, representando a quantidade de dados que deve ser passado para cada célula, 0 significa que a informação não deve ser passada e 1 completamente passada adiante.

4.4.2.5 Estratégia de Previsão e Medidas de Erro

Para a avaliação do modelo de previsão, [Hyndman e Athanasopoulos \(2021\)](#) recomendam que para avaliar a acurácia das previsões o conjunto de dados seja dividido entre teste e treinamento onde o conjunto de teste corresponde geralmente a 20% do total e deve ser pelo menos tão longínquo quanto o horizonte de previsão almejado.

A subdivisão entre treino e teste foi feita como em [Siami-Namini, Tavakoli e Namin \(2018\)](#) com 70% dos dados sendo separados para treinamento (ajuste) dos modelos e 30% para teste, além disso foram feitas previsões em três diferentes horizontes de previsão, 3 dias (previsões de curto prazo), 7 dias (previsões de médio prazo) e 14 dias (previsões de longo prazo) para verificar a diferença de previsão em cada horizonte em cada um dos modelos.

Para as medidas de erro, foram utilizados dois tipos de erros, os erros dependentes da escala, dentre os quais temos neste trabalho o erro médio quadrático (do inglês com sigla RMSE, do inglês *Root Mean Squared Error*) e o erro médio absoluto (com sigla MAE, do inglês *Mean Absolute Error*) e os erros percentuais sendo usado o erro médio simétrico absoluto percentual (com sigla sMAPE, do inglês *Symmetric Mean Absolute Percentage Error*)

Tanto o RMSE (**Equação 4.11**) quanto o MAE (**Equação 4.12**) de interesse devem ser os menores na escolha de modelos, minimizar o MAE leva a previsões da mediana, enquanto minimizar o RMSE leva a previsões da média, a medida MAE é mais fácil de interpretar, no entanto o RMSE é usado com mais frequência.

$$RMSE = \sqrt{\frac{\sum_{i=1}^N (x_i - \hat{x}_i)^2}{n}}, i = 1, \dots, N \quad (4.11)$$

$$MAE = \frac{\sum_{i=1}^N |x_i - \hat{x}_i|}{n}, i = 1, \dots, N \quad (4.12)$$

O sMAPE (**Equação 4.13**) é uma medida alternativa ao erro médio absoluto percentual (com sigla MAPE, do inglês *Mean Absolute Percentage Error*):

$$sMAPE = \sum_{t=1}^N 200 \frac{|x_t - \hat{x}_t|}{n(x_t + \hat{x}_t)}, t = 1, \dots, N \quad (4.13)$$

A vantagem dos erros percentuais é que eles são livres de unidade e podem ser usados frequentemente para comparar diferentes conjuntos de dados, no entanto o MAPE possui uma desvantagem por penalizar mais erros negativos, o que levou ao desenvolvimento do sMAPE que possui também alguns pontos de atenção visto que se x_t é próximo de zero, $\hat{x}_t$ possivelmente também será, o que pode tornar o cálculo instável, outro ponto é que o valor do sMAPE pode ser negativo, portanto não sendo uma medida de percentual absoluto,

devido a essas complicações essa medida foi avaliada conjuntamente com o RMSE e o MAE.

4.4.2.6 Intervalos de Previsão

Os intervalos de previsão são uma maneira bastante útil de representar a incerteza presente nas previsões, um intervalo de previsão de 95% contém os valores que devem incluir o real valor futuro com uma probabilidade de 95%, ainda segundo Hyndman e Athanasopoulos (2021) assumindo que a distribuição das futuras observações é normal, um intervalo de previsão de 95% para a previsão h pode ser descrito como na equação 4.14, em que c depende da probabilidade de cobertura do intervalo, sendo um quantil $\alpha/2$ da distribuição normal.

$$\hat{y}_{T+h|T} \pm c\hat{\sigma}_h \quad (4.14)$$

O desvio padrão da distribuição das previsões pode ser estimado como na equação 4.15, em que K é o número de parâmetros estimados no método de previsão, e M representa o número de observações faltantes nos resíduos $y_t - \hat{y}_t = e_t$.

$$\hat{\sigma} = \sqrt{\frac{1}{T - K - M} \sum_{t=1}^T e_t^2} \quad (4.15)$$

Os autores Hyndman e Athanasopoulos (2021) ainda propõem métodos de *benchmark* (ou referência) para o cálculo de $\hat{\sigma}_h$, dos quais dois foram selecionados para este trabalho, o método de *benchmark* naïve em que ($\hat{\sigma}_h = \hat{\sigma}\sqrt{h}$) e o da média com ($\hat{\sigma}_h = \hat{\sigma}\sqrt{1 + 1/T}$).

4.4.2.7 Bootstrap Não Paramétrico

O método utilizado para avaliar a estabilidade das previsões foi a realização de um intervalo de confiança *bootstrap*. O *bootstrap* é uma técnica computacional de amostragem com reposição, e é geralmente usado para estimar intervalos de confiança. Representando matematicamente com base em Puth et al. (2015), geralmente temos $\hat{\theta}$ como estimador de um parâmetro populacional θ , no método bootstrap no entanto, desejamos retirar uma quantidade B de amostras e calcular uma estimativa da população para cada uma destas B amostras, terminando com $\hat{\theta}_1^*, \dots, \hat{\theta}_B^*$ estimativas, que após ordenadas, os dois valores que compõem os percentis $100 \times (\frac{\alpha}{2})\%$ e $100 \times (1 - \frac{\alpha}{2})\%$, são utilizados como intervalo de confiança para o parâmetro populacional, o valor utilizado foi de $\alpha = 0,01$ correspondendo a um intervalo construído com nível de 99% de confiança.

Foi construído um algoritmo para utilizar de sementes geradas aleatoriamente para inicialização dos pesos da rede neural recorrente, onde a semente a ser selecionada

foi composta de uma amostra de tamanho 1, sem reposição de um número inteiro dentre os limites 1 até 4000, o algoritmo foi feito para rodar a rede neural com diferentes inicializações 30 vezes, no entanto a quantidade de neurônios na camada escondida se manteve (9 neurônios). Portanto cada tempo h de previsão foi composto por 30 observações, onde 10.000 reamostragens foram realizadas para cada tempo h , a escolha para avaliar a estabilidade das previsões da rede neural recorrente se deu pois esta foi a rede selecionada para mostrar as previsões atualizadas para o ROI.

5 RESULTADOS

A análise estatística foi dividida em duas partes, a primeira contendo técnicas de análise de texto de plataformas como o *Twitter*, *Google Trends* e *Youtube*, métodos estes que são relevantes a nível de *branding* ou de avaliação da percepção da marca por parte do público. A segunda parte detalha os *dashboards* construídos para apresentar o desempenho atualizado das campanhas de *Marketing* realizadas para a VoaL, a métrica principal utilizada para medir a eficiência das campanhas é o ROI, no entanto outras informações também estão disponíveis como a participação de cada canal de conversão e a falta de registro do *Google Analytics* mas não serão apresentadas naas análises a seguir.

5.1 Branding - Reclamações dos Clientes

Para análise de informações a nível de *branding* e da percepção digital dos clientes em relação a VoaL, foram aplicadas algumas técnicas de análise de texto, para avaliar os motivos que causam insatisfações nos clientes, com reclamações que foram postadas em um *site* específico para este fim. No título das reclamações, algumas das palavras mais frequentes, como ilustrado na **Figura 12**, revelam alguns dos diversos motivos que levam o cliente a abrir uma reclamação contra a empresa aérea, com destaque para “passagem”, “reembolso” e “cancelamento”. Já no conteúdo destas reclamações **Figura 13**, as palavras “passagem” e “compra” ganham destaque, bem como as palavras “site” e “email”. Estas últimas podem indicar problemas no contato dos clientes nessas plataformas.

No título das reclamações algumas palavras geralmente aparecem associadas, com uma correlação de Phi maior ou igual a 0,3. Na **Figura 14**, vemos que estão associadas entre si as palavras “nao”, “consigo”, “entrar” e “contato”, revelando mais um dos motivos da insatisfação dos clientes. Essa situação fica aparente, também, na associação entre “falta” e “comunicação”, entre “sem”, “retorno” e “resposta”, ou ainda, entre “ninguém” e “responde”.


Como complemento a busca por palavras associadas no conteúdo das reclamações na **Figura 15**, algumas associações aparecem entre as palavras “segunda”, “reclamacao” ou ainda “varias”, “reclamacoes”, mostrando que o motivo de algumas reclamações foram que os clientes tentaram entrar em contato mais de uma vez com a agência e não conseguiram, ou ainda “precisei”, “cancelar”, que revela reclamações por motivo de problemas com cancelamento da viagem, ou “testei”, “positivo” e “covid”, que podem explicitar problemas gerados no âmbito da pandemia do Sars-CoV-2.

pico de pesquisas mensais pelo termo “VoaL” (**Figura 17**) ocorreu em meados do ano de 2019, sendo que no começo de 2020 houve uma brusca queda na popularidade do termo, não podendo se descartar a hipótese de que possa ter sido por efeito da pandemia da Covid-19.

Figura 16 – Palavras frequentes nas pesquisas relacionadas ao nome da VoaL.




Fonte: Elaboração Própria

Figura 17 – Popularidade do nome da VoaL em pesquisas no *Google*.

Fonte: Elaboração Própria

Em plataformas como o *Youtube* e o *Twitter*, as informações da análise de texto podem trazer ideias de como se adequar a plataforma. No *Youtube* por exemplo, diversas palavras são muito frequentes no título de vídeos que aparecem desde o ano de 2021 até 27-03-2022, na pesquisa pelo termo “VoaL”, ilustrado na **Figura 18** são bastante comuns as palavras “passagens”, “aéreas”. Além disso, com cunho similar os termos “baratas”, “promocionais”, “low”, “cost”, “promocionais”, “barata”, “baratos” e “promocao”, indicando que pode ser interessante uma abordagem mais voltada a divulgação de promoções e trechos de viagens baratos na plataforma.


Figura 21 – Dashboard Shiny Exploratório da API.



Fonte: Elaboração Própria

O intuito do segundo painel é informar os resultados que estão sendo obtidos nas campanhas de *Marketing* realizadas na Voal pela empresa de *Marketing* Digital, este dashboard contém outros tipos de informações gráficas omitidas neste trabalho como a falta de registros da plataforma do *Google Analytics*, para focar na métrica mais importante, que é o ROI e seu acompanhamento diário **Figura 22**, pois revela o retorno do investimento que está sendo realizado na plataforma de *Marketing* do *Google Ads*, a tendência de subida ou queda é evidenciada pela média móvel semanal, sendo crucial para a tomada de decisões das duas instituições (Voal e Otis).

Figura 22 – Dashboard Shiny Descritivo dos Resultados - ROI.




Fonte: Elaboração Própria

5.3 Série Temporal - ROI

Como a série temporal do ROI é diária, para a decomposição de seus componentes foi seguida a recomendação dos autores [Hyndman e Athanasopoulos \(2021\)](#), em que afirmam que se os dados são observados mais de uma vez por semana, então pode haver mais de um padrão sazonal, sendo que dados diários geralmente possuem uma sazonalidade semanal, ou seja, inicialmente a frequência utilizada foi de 7.

A decomposição aditiva da série na **Figura 23** mostra que apesar de não haver tendência, o componente sazonal estava presente na série temporal e além das evidências gráficas de sazonalidade o teste de Kruskal-Wallis forneceu evidências para que a hipótese nula de não-sazonalidade fosse rejeitada a um nível de 5% de significância (p -valor $< 0,0001$). No entanto o teste de Mann-Kendall forneceu evidências para a rejeição da hipótese nula da falta de tendência da série (p -valor $< 0,0001$) contrariando a análise da decomposição aditiva.


Figura 23 – Decomposição da Série Temporal do ROI do Marketing até Março de 2022



Fonte: Elaboração Própria

Além disso, o teste de Kwiatkowski-Phillips-Schmidt-Shin (ou teste KPSS), evidenciou que a um nível de 5% de significância a hipótese nula de estacionariedade poderia ser rejeitada (p -valor = 0,0239), a falta de estacionariedade da série também pode ser evidenciada pela sua autocorrelação (ACF) (**Figura 24**), onde o ACF demora para decair a 0, sendo que o oposto ocorreria em uma série estacionária.

Figura 24 – Autocorrelação nos Lags da Série Temporal do ROI



Fonte: Elaboração Própria

A entropia espectral de *Shannon* computada foi de 0,85, ou seja, bastante próxima de 1, evidenciando que a série do ROI é complicada de se prever, já o teste de não linearidade de Keenan, evidenciou que a série possui um comportamento não-linear (p -valor $< 0,0001$).

Como a série é complexa de prever, não é estacionária e apresenta uma relação não-linear, de acordo com [Hyndman e Athanasopoulos \(2021\)](#) as redes neurais artificiais permitem a modelagem de relações não lineares complexas entre a variável resposta e suas preditoras, logo um modelo da classe ARIMA, não seria o suficiente. Portanto foram considerados modelos de Redes Neurais para a previsão do ROI com diferentes estratégias, as quais serão detalhadas na próxima seção.


5.4 Previsão do ROI

Para realizar a previsão do ROI do investimento em campanhas de *marketing* digital da VoaL realizadas pela agência digital Otis, os resultados foram analisados até o dia 15 de Agosto, onde posteriormente, para que as previsões pudessem estar sempre atualizadas, o modelo mais conveniente em termos de poder computacional, horizonte de previsão, métricas de erro e estabilidade das previsões foram escolhidos para serem incluídos no *dashboard* com análises em tempo real.

Primeiramente foi utilizado o modelo ARIMA como método de comparação às redes neurais, onde a função `auto.arima` foi aplicada aos dados de treinamento, resultando em um modelo ARIMA(2,0,1)(0,0,1)[7], visualmente a comparação dos resultados previstos do modelo em comparação com o conjunto de teste na (**Figura 25**), apesar de prever

uma queda no ROI dos valores iniciais as próximas previsões são extrapoladas como um valor médio.


Figura 25 – Previsões do Modelo ARIMA(2,0,1)(0,0,1)[7].



Fonte: Elaboração Própria

A série temporal foi defasada em três períodos com *lag* 1, *lag* 2 e **lag** 3, que corresponderam as entradas do modelo, após o conjunto de valores do ROI utilizados para o treinamento ser normalizado, o modelo de redes neurais recorrentes composto por nove neurônios na camada escondida foi treinado no conjunto de treino, utilizando a função `trainr` do pacote `rnn` e a função tangente hiperbólica como ativação, sendo que em comparação com o modelo ARIMA e após a realização de diversas simulações para a seleção de entradas com melhor performance nas métricas de erro, a rede neural recorrente foi capaz de realizar uma melhor extrapolação dos dados para o conjunto de teste (**Figura 26**).


Figura 26 – Previsões do Modelo de Redes Neurais Recorrentes Simples



Fonte: Elaboração Própria

Para o treinamento da rede neural LSTM, o pré-processamento de dados do ROI incluiu a normalização dos dados do conjunto de treinamento e como a rede LSTM espera que os dados estejam em modo de aprendizado supervisionado foi necessário incluir uma variável resposta Y (com dados completos) e uma variável preditora X ($lag\ 3$), o modelo LSTM apresentou previsões graficamente bastante similares ao modelo RNN simples e superiores ao modelo ARIMA (**Figura 27**).

Figura 27 – Previsões do Modelo de Redes Neurais Recorrentes LSTM



Fonte: Elaboração Própria

As medidas de erro para o conjunto de teste estão na **Tabela 2**, a rede neural LSTM foi a que teve melhores métricas de erro com o MAE e RMSE mais baixos que os

dois modelos comparados e o SMAPE sendo de 38%, o modelo ARIMA foi o que obteve as piores métricas de erro, com o SMAPE de 57%, sendo 14% maior que o do modelo de redes neurais recorrentes e 19% maior que o LSTM. Além disso a RNN escolhida foi composta de 9 neurônios na camada escondida, diversas tentativas foram feitas antes de chegar nessa configuração, inicialmente a RNN era composta de quatro camadas escondidas com 6, 1, 9 e 4 neurônios, no entanto essa configuração resultou em maiores medidas de erro como o SMAPE (44%) e em um maior tempo de processamento da função de treinamento (5,52 segundos).

Tabela 2 – Medidas de Erro no Conjunto de Teste.

Modelos de Previsão	MAE	SMAPE	RMSE
ARIMA(2,0,1)(0,0,1)[7]	1,59	0,57	1,82
RNN	1,03	0,43	1,31
LSTM	0,83	0,38	1,05

Após avaliar os modelos com diferentes parâmetros e escolher os que apresentaram melhores resultados, vamos apresentar as previsões, além do conjunto de teste, as previsões em diferentes períodos de tempo presentes na **Tabela 3**, mostram que o modelo com melhores previsões para um longo período de tempo (14 dias) foi a rede neural recorrente, além disso para todos os períodos de tempo tanto o RMSE quanto o MAE foram abaixo de 1 para o modelo, no entanto o modelo ARIMA apresentou métricas levemente melhores para o período de 7 dias, a performance do modelo LSTM apenas foi levemente melhor que o modelo RNN no período de 7 dias para as métricas MAE e RMSE.

Tabela 3 – Medidas de Erro dos Modelos Ajustados.

Horizonte de Previsão Modelos	Curto Período (3 dias)			Médio Período (7 dias)			Longo Período (14 days)		
	MAE	SMAPE	RMSE	MAE	SMAPE	RMSE	MAE	SMAPE	RMSE
ARIMA	1,11	0,43	1,14	0,54	0,21	0,68	0,72	0,28	0,85
RNN	0,82	0,32	0,93	0,58	0,23	0,71	0,68	0,27	0,84
LSTM	1,04	0,40	1,08	0,57	0,21	0,84	0,79	0,32	1,11

6 DISCUSSÃO

Na primeira parte do trabalho foram apresentadas ferramentas de *web analytics* utilizadas para mensurar o *marketing* digital, além disso nos resultados foi utilizada a Estatística para auxiliar na análise de *branding*, onde os dados de redes sociais, sites de reclamações e da plataforma do Google (*Google Trends*) foram analisados por meio de técnicas de análise de texto como nuvens de palavras e a quantificação da correlação entre palavras, este tipo de análise foi relevante pois possibilita uma análise que traz conhecimento sobre os seguidores da companhia aérea em redes sociais, saber qual o motivo das reclamações dos consumidores da VoaL e verificar os picos de popularidade de buscas sobre a VoaL no Google.

Dentre os modelos de previsão para o ROI o que apresentou melhor resultado nas medidas de erro em comparação ao conjunto de testes foi o modelo LSTM, superando portanto o modelo ARIMA, um resultado esperado e convergente com o estudo realizado por [Siami-Namini, Tavakoli e Namin \(2018\)](#), os autores ainda concluem o artigo falando sobre a importância de utilizar métodos de aprendizado profundo (como as redes LSTM) para a previsão de dados econômicos e financeiros.

A importância dos métodos de aprendizado profundo também foi verificada neste trabalho na previsão do ROI, visto que tanto a rede neural recorrente simples quanto a LSTM tiveram erros menores que o modelo ARIMA para o conjunto de teste. Além disso, o modelo ARIMA extrapolou as previsões para a média no conjunto de testes.

Dada a entropia espectral de shannon calculada de 0,85 (valor considerado alto, evidenciando a dificuldade de previsão da série temporal), os testes realizados também mostram essa complexidade da série, como o KPSS que indicou a falta de estacionariedade da série, e o teste de não linearidade de Keenan, apontando para um possível comportamento não linear da série, foram importantes para levar em consideração os dois modelos de redes neurais, dos quais resultaram em boas previsões do ROI.

Posteriormente, um modelo precisou ser selecionado para fazer parte do dashboard shiny, entretanto apesar do modelo LSTM ter apresentado a melhor previsão para o conjunto de testes, a rede LSTM foi mais computacionalmente intensa que o modelo RNN e o ARIMA, utilizando a função `system.time` apenas o tempo necessário para rodar as funções de treinamento foram de 64,61 (LSTM em segundos), 3,59 (RNN em segundos) e 0,31 (ARIMA em segundos).

Como o modelo de redes neurais recorrentes teve uma boa previsão para 14 dias, superando o ARIMA no conjunto de testes e apresentou um decréscimo de 94% no tempo de processamento da função de treinamento em relação ao modelo LSTM, a rede


neural recorrente simples foi escolhido para mostrar as previsões atualizadas no dashboard.

6.1 Estabilidade das previsões

Como a inicialização dos pesos da rede neural recorrente é aleatória e depende basicamente da semente escolhida para avaliar a estabilidade das previsões. Para isso, o método utilizado para avaliar essa estabilidade foi a realização de um intervalo de confiança *bootstrap* da rede neural recorrente com 9 neurônios, a qual foi a rede selecionada para mostrar as previsões atualizadas no *dashboard*. Os resultados do intervalo de confiança *bootstrap* na (Figura 28) mostram que pela largura dos intervalos ser muito curta, para essas 30 inicializações aleatórias houve uma estabilidade nas previsões, independentemente dos pesos de inicialização.

No entanto, vale ressaltar que houveram algumas limitações que tiveram que ser consideradas na construção do algoritmo para inicialização de pesos diferentes, em algumas das sementes utilizadas, a função de treinamento `trainr` apresentava um comportamento atípico, a inicialização dos pesos poderia gerar erros altos demais e com valores constantes, para passar por esse problema todas as sementes que passaram de um erro médio acima de 0,5 foram puladas, o valor médio foi escolhido pois em diversas inicializações a média dos erros ficou abaixo desse valor.

Figura 28 – Intervalo Bootstrap 99% para as previsões da Rede Recorrente.




Fonte: Elaboração Própria

6.2 Construção de intervalos de previsão


Foram feitos intervalos de previsão para o modelo de redes neurais recorrentes escolhido, com uma cobertura de 95%, os métodos de referência para construção dos intervalos foram o *naïve* e o de *média*, a quantidade de parâmetros utilizados para a estimação de $\hat{\sigma}_h$ foram 3, de acordo com os parâmetros de peso estimados pelo modelo de redes neurais recorrentes.

Os intervalos da (**Figura 29**) se diferenciam dos intervalos simulados pelo método *bootstrap*, pois estes tem o objetivo de representar a incerteza das previsões sobre o futuro valor real, a grande diferença entre os intervalos *naïve* (**Figura 29 (a)**) e da *média* (**Figura 29 (b)**) é que utilizando do método de referência *naïve*, a incerteza cresce com o aumento do horizonte de previsão, enquanto no *benchmark* da *média* o intervalo se mantém constante. Por ter limites superiores e inferiores mais bem definidos, além de possuir uma melhor visualização, para o *dashboard*, o método escolhido para cálculo do $\hat{\sigma}_h$ e subsequente construção do intervalo de previsão foi o do *benchmark* da *média*.

Figura 29 – Intervalo de predição 95% para o modelo RNN.



(a) Referência Naïve



(b) Referência Média

7 CONSIDERAÇÕES FINAIS

7.1 Limitações

Dentre algumas limitações do trabalho está o fato dos dados serem atualizados em tempo real, logo algumas conclusões referentes aos seguidores da VoaL e outras análises de *branding* podem mudar de acordo com o tempo, assim como o comportamento da série temporal do ROI pode vir a se alterar completamente, o que pode ter impacto sobre os testes realizados, outro fato importante desta atualização constante é que o conjunto de treinamento é alimentado constantemente, com isso a estrutura do modelo de previsão pode precisar ser revista.

7.2 Conclusão

Diversos métodos para avaliação estatística do impacto de campanhas de *marketing* foram apresentados neste trabalho, em que por meio de ferramentas que possibilitam a medição de interações no *website* da VoaL, bancos de dados, *web scrapping* e acesso APIs, foi possível ratificar como a Estatística está inserida no contexto do *Marketing* Digital, não apenas para a mensuração do retorno financeiro, mas também para análise de dados de redes sociais e coleta de dados de fontes de terceiros disponíveis na internet e cruzamentos de dados.

Os testes realizados e a análise descritiva da série foram importantes para a consideração dos modelos de redes neurais, assim como a literatura prévia, apesar do modelo LSTM ter apresentado as melhores medidas de previsão, o modelo de redes neurais recorrentes simples além de ter sido superior ao modelo ARIMA, foi o mais eficiente no quesito computacional para ser incluído no painel com atualizações constantes, por fim a utilização de *dashboards* para verificação dos resultados atualizados se mostrou um ativo bastante importante para verificação rápida e fácil dos resultados das ações de *marketing* digital para a VoaL.

Apesar do resultado satisfatório dos modelos LSTM e RNN para a previsão, os resultados foram obtidos utilizando dados diários, visando pesquisas futuras, na análise de texto mudanças podem ser realizadas para verificação de correlação entre palavras e para criação das nuvens de palavras, como a remoção dos radicais e uso de técnicas como análise de sentimento.

Para pesquisas futuras na parte de predição, com as posteriores atualizações da série temporal propõe-se que sejam consideradas novas frequências para previsão (previsão do ROI mensal), o que pode levar a uma alteração no modelo utilizado, além disso podem

ser considerados outros modelos insurgentes, como o modelo neural prophet apresentado pelos autores [Triebe et al. \(2021\)](#) da empresa Meta (antigo Facebook) e outros modelos que compõem o estado da arte de aplicações de redes neurais, em conjunto com a discussão e aprimoramento de diferentes métodos para avaliar a estabilidade das previsões e seus intervalos de previsão.

REFERÊNCIAS

- ABIODUN, O. I. et al. State-of-the-art in artificial neural network applications: A survey. **Heliyon**, v. 4, n. 11, 2018. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2405844018332067>>.
- ARMSTRONG, J. S.; BRODIE, R. J.; MCINTYRE, S. H. Forecasting methods for marketing: Review of empirical research. **International Journal of Forecasting**, v. 3, p. 355–376, 1987.
- BOTCHKAREV, A.; ANDRU, P. A return on investment as a metric for evaluating information systems: Taxonomy and application. **Interdisciplinary Journal of Information, Knowledge, and Management**, v. 6, p. 245 – 269, 2011. doi:<<https://doi.org/10.28945/1535>>.
- BREZAK, D. et al. A comparison of feed-forward and recurrent neural networks in time series forecasting. **IEEE Conference on Computational Intelligence for Financial Engineering Economics (CIFEr)**, 2012. doi:<[10.1109/cifer.2012.6327793](https://doi.org/10.1109/cifer.2012.6327793)>.
- BRYN, M. **Using Google Analytics with R**. 2016? Acessado em: 12/10/2022. Disponível em: <<https://michalbryns.gitbooks.io/r-google-analytics/content/>>.
- BURN, D. H.; ELNUR, M. A. H. Detection of hydrologic trends and variability. **Journal Of Hidrology**, v. 255, p. 107 – 122, 2002. doi:<[doi:10.1016/S0022-1694\(01\)00514-5](https://doi.org/10.1016/S0022-1694(01)00514-5)>.
- CARVALHO, A. Silva de; FRANCISCO, E. de R. Analytics como ferramenta para insight de negócio com dados não estruturados. **EnANPAD 2017**, São Paulo/SP, 2017. Disponível em: <http://www.anpad.org.br/abrir_pdf.php?e=MjM3MTA=>.
- Data Science Academy. **Deep Learning Book: Capítulo 48 – Redes Neurais Recorrentes**. 2022? Acessado em: 31/08/2022. Disponível em: <<https://www.deeplearningbook.com.br/redes-neurais-recorrentes/>>.
- DIAMOND, S. **Digital Marketing All-In-One For Dummies**. 9st. ed. [S.l.]: John Wiley Sons, Inc, 2019. ISBN 978-1-119-56023-4.
- FILHO, L. J. S.; CAMPOS, M. F. D. O uso da média móvel como indicador de tendência: Do mercado financeiro ao acompanhamento dos casos de covid-19. **Revista Negócios em Projeção**, v. 12, n. 2, p. 73–81, 2021.
- GOERG, G. M. **Forecastable Component Analysis (ForeCA)**. [S.l.]: arXiv, 2012. doi:<<https://doi.org/10.48550/arxiv.1205.4591>>.
- Google Developers. **Install Google Tag Manager for web pages**. 2022. Acessado em: 12/02/2022. Disponível em: <<https://developers.google.com/tag-platform/tag-manager/web>>.
- HYNDMAN, R.; ATHANASOPOULOS, G. **Forecasting: principles and practice**. 3rd. ed. Melbourne, Australia: OTexts, 2021. Acessado em: 19/05/2022. Disponível em: <<https://otexts.com/fpp3/>>.
- HYNDMAN, R. J. **Moving averages**. 2009. Acessado em: 08/04/2022. Disponível em: <<https://robjhyndman.com/papers/movingaverage.pdf>>.

- JÄRVINEN, J.; KARJALUOTO, H. The use of web analytics for digital marketing performance measurement. **Industrial Marketing Management**, v. 50, p. 117–127, 2015.
- KAMAL, Y. Study of trend in digital marketing and evolution of digital marketing strategies. **International Journal of Engineering Science and Computing**, v. 6, n. 5, p. 5300 – 5302, 2016. doi:<[10.4010/2016.1298](https://doi.org/10.4010/2016.1298)>.
- KOLAJO, T.; DARAMOLA, O.; ADEBIYI, A. Big data stream analysis: a systematic literature review. **Journal of Big Data**, v. 6, n. 47, 2019. doi:<<https://doi.org/10.1186/s40537-019-0210-7>>.
- LEE, T.-H.; WHITE, H.; GRANGER, C. W. Testing for neglected nonlinearity in time series models: A comparison of neural network methods and alternative tests. **Journal of Econometrics**, v. 56, n. 3, p. 269–290, 1993. ISSN 0304-4076.
- MORETTIN, P. A.; TOLOI, C. M. d. C. **Análise de séries temporais**. [S.l.]: Edgard Blucher, 2004.
- NIELSEN, H. B. **Non-Stationary Time Series and Unit Root Tests**. 2005. Acessado em: 01/06/2022. Disponível em: <https://web.archive.org/web/20161130133316/http://www.econ.ku.dk/metrics/Econometrics2_05_II/Slides/08_unitroottests_2pp.pdf>.
- PUTH, M.-T. et al. On the variety of methods for calculating confidence intervals by bootstrapping. **Journal of Animal Ecology**, v. 84, n. 4, 2015. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2405844018332067>>.
- Richard Wanjohi. **Time Series Forecasting using LSTM in R**. 2018. Acessado em: 25/08/2022. Disponível em: <<http://rwanjohi.rbind.io/2018/04/05/time-series-forecasting-using-lstm-in-r/>>.
- ROSÁRIO, A.; MONIZ, L. B.; CRUZ, R. Data science applied to marketing: A literature review. **Journal of Information Science Engineering**, v. 37, n. 5, p. 1067–1081, 2021. <<http://hdl.handle.net/10362/130689>>.
- SIAMI-NAMINI, S.; TAVAKOLI, N.; NAMIN, A. S. A comparison of arima and lstm in forecasting time series. **2018 17th IEEE International Conference on Machine Learning and Applications (ICMLA)**, p. 1394–1401, 2018.
- SILGE, J.; ROBINSON, D. **Text Mining with R: A Tidy Approach**. 1st. ed. [S.l.]: O'Reilly Media, Inc., 2017. ISBN 1491981652.
- TRIEBE, O. et al. **NeuralProphet: Explainable Forecasting at Scale**. 2021. Disponível em: <<https://arxiv.org/abs/2111.15397>>.
- VILLAVICENCIO, N. G. F. El declive del roi social. **Anuario ThinkEPI**, v. 8, p. 264–268, 2014. Disponível em: <<https://thinkepi.profesionaldelainformacion.com/index.php/ThinkEPI/article/view/29591>>.
- WEBER, J. **Practical Google Analytics and Google Tag Manager for Developers**. [S.l.]: Apress, 2015.
- WONG, B. K.; BODNOVICH, T. A.; SELVI, Y. Neural network applications in business: A review and analysis of the literature (1988–1995). **Decision Support Systems**, v. 19, n. 4, p. 301–320, 1997. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S016792369600070X>>.

ZEROUAL, A. et al. Deep learning methods for forecasting covid-19 time-series data: A comparative study. **Chaos, Solitons Fractals**, v. 6, n. 47, p. 110121, 2019. doi:<<https://doi.org/10.1016/j.chaos.2020.110121>>.

ZHANG, Z. **Text Mining for Social and Behavioral Research Using R: A Case Study on Teaching Evaluation**. 2018. Acessado em: 28/03/2022. Disponível em: <<https://books.psychstat.org/textmining/>>.